统计推断在数模转换系统中的应用

50组 孙煜 5130309236

摘要: 本课程要运用 Matlab 软件,采用模拟退火算法统计 469 组数据(每组 51 个),并结合统计推断学的方法,完成从特征点的选取、特征点反推曲线关系到最后的方案评估等一系列过程,旨在提出一个合理的数学模型,学会从少量数据点推断大量数据点的方法。最终得出结论

关键词: 拟合,算法实现,最优解

1. 引言

统计推断[statistical inference] 根据带随机性的观测数据(样本)以及问题的条件和假定(模型),而对未知事物做出的,以概率形式表述的推断。统计推断问题常表述为如下形式:所研究的问题有一个确定的总体,其总体分布未知或部分未知,通过从该总体中抽取的样本(观测数据)做出与未知分布有关的某种结论。

在工程实践中,我们常借助统计推断的理念,对变量间的函数关系进行分析。通常选取能代表变量之间关系的特征点,经过多种拟合方式进行拟合,从而求解出能够代表海量变量之间函数关系的最优化方式。

2. 课题概述

假定有某型投入批量试生产的电子产品,其内部有一个模块,功能是监测某项与外部环境有关的物理量(可能是温度、压力、光强等)。该监测模块中传感器部件的输入输出特性呈明显的非线性。本课题要求为该模块的批量生产设计一种成本合理的传感特性校准(定标工序)方案。

3. 研究目的

考虑到工业化生产下的成本、效率因素,针对该系统的某一实例,实测其 51 个输出电压对应的输入是不经济的。因而考虑跳点测定,在保证所要求精度的前提下,通过测定 7 组电压值(即特征点)对应的被检测物理量来推断整体的输入一输出电压(U)特性关系研究给定的样本的这一特性关系,确定这 7 个特征点,并提出由此特征点集推断出整体特性关系的函数逼近方法,最后评估该方案对给定样本的适用度。

4. 模型

为了对本课题展开有效讨论,需建立一个数学模型,对问题的某些方面进行必要的描述 和限定。

监测模块的组成框图如图 1。其中,传感器部件(包含传感器元件及必要的放大电路、调理电路等)的特性是我们关注的重点。传感器部件监测的对象物理量以符号 Y 表示;传感部件的输出电压信号用符号 X 表示,该电压经模数转换器(ADC)成为数字编码,并能

被微处理器程序所读取和处理,获得信号 $\hat{\mathbf{Y}}$ 作为 \mathbf{Y} 的读数(监测模块对 \mathbf{Y} 的估测值)。




图 1 监测模块组成框图

所谓传感特性校准,就是针对某一特定传感部件个体,通过有限次测定,估计其 Y 值与 X 值间——对应的特性关系的过程。数学上可认为是确定适用于该个体的估测函数 $\hat{\mathbf{y}} = \mathbf{f}(\mathbf{x})$ 的过程,其中 x 是 X 的取值, $\hat{\mathbf{y}}$ 是对应 Y 的估测值。

考虑实际工程中该监测模块的应用需求,同时为便于在本课题中开展讨论,我们将问题限于X为离散取值的情况,规定

$$X \in \{x_1, x_2, x_3, ..., x_{50}, x_{51}\} = \{5.0, 5.1, 5.2, ..., 9.9, 10.0\}$$

相应的 Y 估测值记为 $\hat{y}_i = f(x_i)$, Y 实测值记为 y_i , i = 1, 2, 3, ..., 50, 51。

1.传感部件特性




图 2 传感特性图示

一个传感部件个体的输入输出特性大致如图 2 所示,有以下主要特征:

- Y 取值随 X 取值的增大而单调递增;
- X 取值在[5.0,10.0]区间内, Y 取值在[0,100]区间内;
- 不同个体的特性曲线形态相似但两两相异;
- 特性曲线按斜率变化大致可以区分为首段、中段、尾段三部分,中段的平均斜率小 于首段和尾段;
- 首段、中段、尾段单独都不是完全线性的,且不同个体的弯曲形态有随机性差异;

● 不同个体的中段起点位置、终点位置有随机性差异。 为进一步说明情况,图 3 对比展示了四个不同样品个体的特性曲线图示。

2.标准样本数据库

前期已经通过试验性小批量生产,制造了一批传感部件样品,并通过实验测定了每个样品的特性数值。这可以作为本课题的统计学研究样本。数据被绘制成表格,称为本课题的"标准样本数据库"。

该表格以 CSV 格式制作为电子文件。表格中奇数行存放的取值,偶数行存放对应的取值。第 2i-1 行存放第 i 个样本的 X 数值,第 2i 行相应列存放对应的实测 Y 数值。




图 3 四个不同样本个体特性图示对比

3.成本计算

为评估和比较不同的校准方案,特制定以下成本计算规则。

● 单点定标误差成本

$$s_{i,j} = \begin{cases} 0 & \text{if } \left| \hat{y}_{i,j} - y_{i,j} \right| \le 1 \\ 1 & \text{if } 1 < \left| \hat{y}_{i,j} - y_{i,j} \right| \le 2 \\ 2 & \text{if } 2 < \left| \hat{y}_{i,j} - y_{i,j} \right| \le 3 \\ 4 & \text{if } 3 < \left| \hat{y}_{i,j} - y_{i,j} \right| \le 5 \\ 10 & \text{if } \left| \hat{y}_{i,j} - y_{i,j} \right| > 5 \end{cases}$$

$$(1)$$

单点定标误差的成本按式(1)计算,其中 $y_{i,j}$ 表示第 i 个样本之第 j 点 Y 的实测值, $\hat{y}_{i,j}$ 表示定标后得到的估测值(读数),该点的相应误差成本以符号 $s_{i,j}$ 记。

● 单点测定成本

实施一次单点测定的成本以符号 q 记。本课题指定 q=20。

● 某一样本个体的定标成本

$$\mathbf{S}_{i} = \sum_{i=1}^{51} \mathbf{S}_{i,j} + \mathbf{q} \cdot \mathbf{n}_{i} \tag{2}$$

对样本i总的定标成本按式(2)计算,式中 n_i 表示对该样本个体定标过程中的单点测定次数。

● 校准方案总体成本

按式(3)计算评估校准方案的总体成本,即使用该校准方案对标准样本库中每个样本 个体逐一定标,取所有样本个体的定标成本的统计平均。

$$C = \frac{1}{M} \sum_{i=1}^{M} S_i \tag{3}$$

总体成本较低的校准方案,认定为较优方案。

5. 方法探索

1. 暴力穷举法

对于此种问题,最简单也是最能反映整体的方法是暴力穷举法。但是由于数据过多,需要进行 C_{49}^7 次拟合或者求解方程,而这对于普通的计算机来说,是个巨大的数目,无法进行如此多的拟合,或者求解多项式。因此,必须改变算法,利用统计知识来求解。

2. 分段枚举法

对于给定的 51 个点,分成 7 段,每段 7-9 个点进行求取。由于在对一个样本进行测量时,我们需要兼顾在各个不同范围内的数据情况,因此,51 个点应当是离散的,又由于其整体图线线性程度较高,故可以较为均匀地对 51 个点进行分段。对于每一段的数值进行穷举,求得 C 的最小值对应点。可以减少暴力穷举法消耗的时间,但是所需时间依旧很多。

3. 模拟退火法

在温度较高的情况下,系统有较大的概率接受误差较大的分子(类比于温度较高时,各分子的动能波动范围大),此种模糊判断的好处是避免了系统过快地局部收敛。随着温度的降低,可接受变异误差范围逐渐减小,最终趋于稳定,即得出最优解

4. 遗传算法


首先随机选择亲代样本,对其进行评估,筛选掉适应度较低的样本,留下适应度高的样本,并对适应度高的样本进行交叉配对,产生第二代。再从整体中随机取得另一部分样本加入第二代。通过不断产生下一代,适应度高的样本逐渐留下来,适应度低的样本被淘汰,最后得到适应度最高的一组。此种算法可以大大减少计算时间,不过由于程序较为繁琐,对于编程人员要求较高,未能实现。

6. 方法选择及算法实现

1. 方法选择

本组选用模拟退火算法,模拟退火算法来源于固体退火原理,将固体加温至充分高,再让其徐徐冷却,加温时,固体内部粒子随温升变为无序状,内能增大,而徐徐冷却时粒子渐趋有序,在每个温度都达到平衡态,最后在常温时达到基态,内能减为最小。根据 Metropolis 准则,粒子在温度 T 时趋于平衡的概率为 $e^-\Delta E/(kT)$,其中 E 为温度 T 时的内能, ΔE 为其改变量,k 为 Boltzmann 常数。用固体退火模拟组合优化问题,将内能 E 模拟为目标函数值 f,温度 T 演化成控制参数 t,即得到解组合优化问题的模拟退火算法:由初始解 i 和控制参数初值 t 开始,对当前解重复 "产生新解→计算目标函数差→接受或舍弃"的迭代,并逐步衰减 t 值,算法终止时的当前解即为所得近似最优解,这是基于蒙特卡罗迭代求解法的一种启发式随机搜索过程。

其算法流程如下



2. 计算 C 值

设矩阵 Xij (i=1,2,…,419; j=1,2,…,51), Yij (i=1,2,…,419; j=1,2,…,51),

某个解 (S1, S2, …, S7)

6.2.1 对应关系 f

为方便,设对应关系为 Y=f(X)。

三次拟合法下,对每个 Xi, 只需对取得的七个点进行三次多项式拟合,即可得 fi(X)。 (其中 i=1,2,3....418)。

三次样条插值法中,Xi, sk-1 到 Xi, sk 之间的 Y-X 关系由过 Sk-1, Sk, Sk+1, Sk+2 四点的三次曲线确定,设曲线方程为 $Y=a1X^3+a2X^2+a3X+a4$ 。由四点的值可以求得对应的系数值。所以对每个 i, 可以得到一个分段函数形式的 Y=f (X) 。

其它拟合法下类似。

6.2.2 由 f 得到对应 M 值

对于矩阵 Xi j(i=1, 2, ···, 419; j=1, 2, ···, 51)中的每一个值,代入 Y=f(X)中,得到 矩阵 Y i j (i=1, 2, ···, 419; j=1, 2, ···, 51)。

然后根据 3.3 的(1)(2)(3)式得出对应的 M。

3. 获得最优解

对所得的算法,考虑其运算时间和成本,可信度等,总结出最优的解。由于算法部分 仍未全部完成,所以其具体分析留待算法完成后进行。

4. 算法的实现及程序运行结果

详细算法请见附录,其中代码选用模拟退火法和三次样条插值拟合,取点个数为7个, (由于在其他拟合法或取点个数的情况下,代码差别不大,因此仅附上得到最优解的代码。 若要测试其他情况,只需修改 best_array 元素个数和初值,或者修改 get_score 中的拟合函数)

最好的运行结果为三次样条插值拟合下

取[2, 9, 20, 26, 34, 45, 50] 成本为 93.8998

7. 结果分析

通过模拟退火法和三次样条插值法得出的最低成本为 93.8998。事实上,通过多组数据的观察,该种取点与拟合法得到的成本固定在 94 左右。在我将 spline 插值换作 cubic 插值后,结果并无明显变化,所以在后续的运行中沿用 spline 插值,同时也便于 test 程序的检验。

由于取点的个数受到已有经验的影响,因此一开始便选作7个,但是仅凭单一种取点个数得到的结论具有局限性,于是我又尝试了其他个数的情况,其中换作取5个点和6个点时,均不能得到成本为110以下的解(在我的程序中,初始最优解的成本应小于110,可在代码内看出),只有在取点个数为8的时候,可得到成本为105左右的解,仍大于已得的最小成本。故三次样条插值法下7个点的取法最优。

然后我又考虑改变拟合的方法,即将三次样条插值法改作多项式拟合。首先尝试的是 3 次多项式拟合。结果不尽人意,在取点个数为 5, 6, 7, 8 的情况下都未能取得成本小于 110 的解。接着我又尝试了 4 次的拟合,本来在以往的观测中 4 次似乎较 3 次更优,可是还是未能得出成本小于 110 的解,在 7 个点的情况下最好,但成本仍在 115 左右。不知道是否是运行代数的缘故,多项式拟合未能取得好的结果。

所以我最后得出的结论为三次样条插值法下取7个点的计算成本最小。

8. 心得体会及工作展望

第一次接触到 Matlab 这个软件,难免感到十分生疏,不过好在 Matlab 的设计十分的人性化,上手起来并不是很难。虽然说起来 Matlab 比 c++感觉更人性化,但是毕竟我接触的还只是最基本的一些操作,即使对于 Matlab 中数组和矩阵,其灵活的操作方法总是容易让我混淆,不过好在到最后还是成功得到了结果。

但在这一过程中还存在一些问题,比如在模拟退火的代码中,对于变动的那个元素,我 仅限定了它的粗略范围,但没有添加防止其与其他元素重复的情况,这样在运行中,出现重 复情况后,会导致三次样条插值错误,使程序停止。我有考虑过添加代码进行判断,可是修 改后的代码由于多了这一判断的操作会是运行的效率降低,运行时间变得很长(可能是我写 的判断代码还不够好),考虑到运行时间问题以及出现重复的概率非常低,因此我还是选择 沿用开始的代码。这一问题是我在以后的过程中需要优化的,毕竟对于使用者,无论出错的 概率多小,程序都应避免。

然后,在与老师的免谈是十分重要的一环。因为在面谈之前,我的代码存在漏洞,得出的结果和测试程序得到的大不相同,本来我以为只是因为与测试程序的拟合法不一样,可是老师指出先解决这个才是首要,于是我又回去经过调试,发现原代码中确实存在问题,原来得到的结果也不为最优解,最后经修改终于得到了和测试程序一样的结果。

虽然最后得出了结果,但是该问题的解决还存在诸多路径去探寻。比如遗传算法,本来考虑在面谈之后尝试下,但是由于面谈中发现了问题,解决之后对我来说时间就不太充足了,于是没有做遗传算法这一块。事实上,遗传算法算法与退火法都是对当前的最优解进行扰动,而避免所得到最优解为局部最优解的过程,只是遗传算法更精细,结果受随机影响的概率较小。当然,这并不代表退火法不够好,它计算过程简单,算法通用,可用于求解复杂的非线性优化问题。其实,在编写遗传算法算法的过程中,可以局部应用退火法,使算法效率更高。不过,这就是在完成遗传算法以后的事了。

总的来说,通过这个课程,学到了许多,不仅是数学工具的使用,也有研究方法等,对 报告的编写也有了一定认识。比较遗憾的是,程序不尽完美,遗传算法没有完成。不过就当 作是以后的努力的方向。

9. 参考文献

- [1] 统计与推断讲座 3: 问题的求解路经.ppt
- [2]统计推断: 第 nn 组(组长姓名)课程报告设计. doc
- [3] "统计推断"课程设计的要求 V2. 0 2014-10-10. doc
- [4] 陈华根,吴健生,王家林,陈冰 模拟退火算法机理研究 同济大学学报(自然科学版) 第32 卷第6 期 2004 年 6 月
- [5] 曲强,陈雪波 基于MATLAB的模拟退火算法的实现 鞍山科技大学学报 26 卷第 3 期 2003 年 6 月
 - [6]雷英杰. 张善文。 MATLAB 遗传算法工具箱及应用。西安电子科技大学出版社

附录

程序源代码:

```
Main.m
```

```
data=csvread('20141010dataform.csv'); %读取数据
best array=zeros(1,7);%best array 用来储存结果相对较好的数组
best cost=0;
sum cost=0;
T=100;
cost=200;%初始化平均得分
while cost>=110 %找到一个平均成本小于 110 的数组,用于稍后微调
   sum cost=0;
    arr1=randi([43,51]);
    arr2=randi([36,42]);
    arr3=randi([29,35]);
    arr4=randi([22,28]);
    arr5=randi([15,21]);
    arr6=randi([8,14]);
    arr7=randi([1,7]);
    random array=[arr7,arr6,arr5,arr4,arr3,arr2,arr1];%产生初始解
    for i=1:469;
        temp=data([2*i-1,2*i],:);
       y base=temp(2,:);
       x base=temp(1,:);
       x tmp=x base(1,random array);
       y tmp=y base(1,random array);
       sum_cost=sum_cost+Get_cost(x_base,y_base,x_tmp,y_tmp);
    end
    cost=sum cost/469;
   best cost=cost;
   best array=random array;
end
while T > 0.1
   T = T/(1+0.05);
   sum cost=0;
    disp(cost)
```

```
for i=1:7
        while true
            b=random_array(i);
            c=randi(3);
            b=b+c-2;
            if (b>0&&b<=51)%保证产生变动时不会超过范围
                break
            end
        end
        random array(i)=b;
    end
    for i=1:469;
        temp=data([2*i-1,2*i],:);
        y base=temp(2,:);
        x base=temp(1,:);
        x tmp=x base(1, random array);
        y tmp=y base(1,random array);
        sum cost=sum cost+Get cost(x base, y base, x tmp, y tmp);
    end
    cost=sum cost/469;
    e=exp(-(cost-best cost)/T*100);
    if (cost<=best cost)</pre>
        best cost=cost;
        best_array=random_array;
    elseif(rand>e)%以1-exp(-成本差/温度)的概率不接受改变
        random array=best array;
    end
end
disp(best array);
disp(best cost);
Get cost.m
function re=Get cost(x base, y base, x tmp, y tmp)
per cost=0;
x=[5.0:0.1:10.0];
y=interp1(x tmp,y tmp,x,'spline');
for w=1:51
    d=abs(y(w)-y base(w));
        if d <= 0.5,
            per_cost=per_cost;
        elseif d<=1,</pre>
            per cost=per cost+0.5;
        elseif d<=2,</pre>
            per_cost=per_cost+1.5;
```