



应用随机过程

张 波 商 豪

中国人民大学 统计学院

1/62



GoBack

FullScreen

Close

Quit



第1章 预备知识

- 1.1 概率空间
- 1.2 随机变量与分布函数;
- 1.3 数字特征、矩母函数与特征函数
- 1.4 收敛性
- 1.5 独立性与条件期望

2/62



GoBack

FullScreen

Close

Quit

§1.1 概率空间

随机试验是概率论的基本概念，试验的结果事先不能准确地预言，但具有如下三个特性：

- (1)可以在相同的条件下重复进行；
- (2)每次试验的结果不止一个，但预先知道试验的所有可能的结果；
- (3)每次试验前不能确定哪个结果会出现。





样本点(ω): 随机试验的基本结果

样本空间(Ω): 随机试验所有可能结果组成的集合

基本事件: Ω 中的样本点 ω

必然事件: 样本空间 Ω

不可能事件: 空集 \emptyset

事件: 由基本事件组成的 Ω 中的子集 A

定义 1.1.1 设 Ω 是一个样本空间(或任意一个集合), \mathcal{F} 是 Ω 的某些子集组成的集合族. 如果满足:

- (1) $\Omega \in \mathcal{F}$;
- (2) 若 $A \in \mathcal{F}$, 则 $A^c = \Omega \setminus A \in \mathcal{F}$;
- (3) 若 $A_n \in \mathcal{F}, n = 1, 2, \dots$, 则 $\bigcup_{n=1}^{\infty} A_n \in \mathcal{F}$;

则称 \mathcal{F} 为 σ 代数. (Ω, \mathcal{F}) 称为可测空间, \mathcal{F} 中的元素称为事件.



注：如果 \mathcal{F} 是事件的 σ 代数，则(1) $\emptyset \in \mathcal{F}$; (2) 当 $A_n \in \mathcal{F}$, $n = 1, 2, \dots$, $\bigcap_{n=1}^{\infty} A_n \in \mathcal{F}$.

以 Ω 的某些子集为元素的集合称为(Ω 上的)集类. 对于 Ω 上的任一非空集类 \mathcal{C} , 存在包含 \mathcal{C} 的最小 σ 代数, 即 $\bigcap \{\mathcal{H} | \mathcal{H} \text{ 为包含 } \mathcal{C} \text{ 的 } \sigma \text{ 代数}\}$, 称为由 \mathcal{C} 生成的 σ 代数, 记为 $\sigma(\mathcal{C})$.

定义 1.1.2 设 $\Omega = \mathbb{R}$. 由所有半无限区间 $(-\infty, x)$ 生成的 σ 代数(即包含集族 $\{(-\infty, x), x \in \mathbb{R}\}$ 的最小 σ 代数)称为 \mathbb{R} 上的 Borel σ 代数, 记为 $\mathcal{B}(\mathbb{R})$, 其中的元素称为 Borel 集合. 类似地, 可定义 \mathbb{R}^n 上的 Borel σ 代数 $\mathcal{B}(\mathbb{R}^n)$.

定义 1.1.3 设 (Ω, \mathcal{F}) 是可测空间, $P(\cdot)$ 是定义在 \mathcal{F} 上的实值函数. 如果

- (1) 任意 $A \in \mathcal{F}$, $0 \leq P(A) \leq 1$;
- (2) $P(\Omega) = 1$;



GoBack

FullScreen

Close

Quit



(3) 对 \mathcal{F} 中两两互不相容事件 A_1, A_2, \dots ,
(即当 $i \neq j$ 时, $A_i \cap A_j = \emptyset$)有

$$P\left(\bigcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} P(A_n)$$

则称 P 是 (Ω, \mathcal{F}) 上的概率, (Ω, \mathcal{F}, P) 称为概率空间, $P(A)$ 称为事件 A 的概率.

概率常用性质:

(1) 若 $A, B \in \mathcal{F}$, 则 $P(A \cup B) + P(A \cap B) = P(A) + P(B)$.

(2) 若 $A, B \in \mathcal{F}$, 且 $A \subset B$, 则 $P(A) \leq P(B)$ (单调性).

(3) 若 $A, B \in \mathcal{F}$, 且 $A \subset B$, 则 $P(B - A) = P(B) - P(A)$.



(4) 若 $A_n \in \mathcal{F}, n = 1, 2, \dots$, 则 $P(\bigcup_{n=1}^{\infty} A_n) \leq \sum_{n=1}^{\infty} P(A_n)$

(5) 若 $A_n \in \mathcal{F}$ 且 $A_n \uparrow A$, 即 $A_n \subset A_{n+1}, n = 1, 2, \dots$,
且 $\bigcup_{n=1}^{\infty} A_n = A$, 则 $P(A) = \lim_{n \rightarrow \infty} P(A_n)$ (下连续).

(6) 若 $A_n \in \mathcal{F}$ 且 $A_n \downarrow A$, 即 $A_{n+1} \subset A_n, n = 1, 2, \dots$
且 $\bigcap_{n=1}^{\infty} A_n = A$, 则 $P(A) = \lim_{n \rightarrow \infty} P(A_n)$ (上连续).

完备概率空间: P -零集 (即零概率事件) 的每个子集仍为事件的概率空间 (Ω, \mathcal{F}, P) .

概率空间完备化: 令 \mathcal{N} 代表 Ω 的所有 P -零集的子集的全体.

由 $\{\mathcal{F}, \mathcal{N}\}$ 生成的 σ 代数 (即包含 \mathcal{F} 和 \mathcal{N} 的最小 σ 代数) 称为 \mathcal{F} 的完备化, 记为 $\overline{\mathcal{F}}$. $\overline{\mathcal{F}}$ 中的每个集合 B 都可以表为 $B = A \cup N$ 其中 $A \in \mathcal{F}, N \in \mathcal{N}$, 且 $A \cap N = \emptyset$. 定义

$$\bar{P}(B) = \bar{P}(A \cup N) = P(A).$$

则 P 就被扩张到 $\overline{\mathcal{F}}$ 上.



定义 1.1.4 设 $\{A_n, n \geq 1\}$ 为一集合序列. 令

$$\limsup_{n \rightarrow \infty} A_n = \bigcap_{n=1}^{\infty} \bigcup_{k=n}^{\infty} A_k; \quad \liminf_{n \rightarrow \infty} A_n = \bigcup_{n=1}^{\infty} \bigcap_{k=n}^{\infty} A_k$$

分别称其为 $\{A_n\}$ 的上极限和下极限(上极限有时也记为 $\{A_n, i.o.\}$).

显然有

$$\limsup_{n \rightarrow \infty} A_n = \{w | w \text{ 属于无穷多个 } A_n\} = \bigcap_{k=1}^{\infty} \bigcup_{n=k}^{\infty} A_n$$

$$\liminf_{n \rightarrow \infty} A_n = \{w | w \text{ 至多不属于有限多个 } A_n\} = \bigcup_{k=1}^{\infty} \bigcap_{n=k}^{\infty} A_n$$

从而恒有 $\liminf_{n \rightarrow \infty} A_n \subset \limsup_{n \rightarrow \infty} A_n$.

若 $\liminf_{n \rightarrow \infty} A_n = \limsup_{n \rightarrow \infty} A_n$, 则称 $\{A_n\}$ 的极限存在, 并用 $\lim_{n \rightarrow \infty} A_n$ 表示, 即令 $\lim_{n \rightarrow \infty} A_n = \liminf_{n \rightarrow \infty} A_n = \limsup_{n \rightarrow \infty} A_n$.



特别地, 若对每个 n , 有 $A_n \subset A_{n+1}$ (相应地, $A_n \supset A_{n+1}$), 则称 $\{A_n\}$ 为单调增(相应地, 单调降). 对单调增或单调降序列 $\{A_n\}$, 我们分别令 $A = \bigcup_n A_n$ 或 $A = \bigcap_n A_n$, 称 A 为 $\{A_n\}$ 的极限, 通常记为 $A_n \uparrow A$ 或 $A_n \downarrow A$.

例 1.1.5 设有某人在反复地投掷硬币, 观察硬币朝上的面是正面或反面. $\Omega = \{\text{所有由投掷结果“正面”和“反面”组成的序列}\}$, $\mathcal{F} = \{\Omega \text{的所有子集}\}$, 记 A_n 为第 n 次投掷的是“正面”的事件, 则

9/62

$$\limsup_{n \rightarrow \infty} A_n = \{\text{有无限多个投掷结果是“正面”}\}$$

$$\liminf_{n \rightarrow \infty} A_n = \{\text{除有限多个外, 投掷结果都是“正面”}\}$$

定义 1.1.6 设 (Ω, \mathcal{F}) 是可测空间, $P(\cdot)$ 是定义在 \mathcal{F} 上的实值函数. 如果



GoBack

FullScreen

Close

Quit



$$(1) P(\Omega) = 1;$$

$$(2) \forall A \in \mathcal{F}, 0 \leq P(A) \leq 1;$$

(3) 对两两互不相容事件 A_1, A_2, \dots , (即当 $i \neq j$ 时, $A_i \cap A_j = \emptyset$) 有

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i)$$

则称 P 是 (Ω, \mathcal{F}) 上的概率, (Ω, \mathcal{F}, P) 称为概率空间, \mathcal{F} 中的元素称为事件, $P(A)$ 称为事件 A 的概率.

事件的概率有如下性质:

(1) 若 $A, B \in \mathcal{F}$, 则 $P(A \cup B) + P(A \cap B) = P(A) + P(B)$.

(2) 若 $A, B \in \mathcal{F}$, 且 $A \subset B$, 则 $P(B - A) = P(B) - P(A)$ (可减性).



GoBack

FullScreen

Close

Quit



(3) 若 $A, B \in \mathcal{F}$, 且 $A \subset B$, 则 $P(A) \leq P(B)$ (单调性).

(4) 若 $A_n \in \mathcal{F}, n \geq 1$, 则 $P(\bigcup_{n \geq 1} A_n) \leq \sum_{n \geq 1} P(A_n)$.

(5) 若 $A_n \in \mathcal{F}$ 且 $A_n \uparrow A \in \mathcal{F}$, 则 $P(A) = \lim_{n \rightarrow \infty} P(A_n)$ (从下连续).

(6) 若 $A_n \in \mathcal{F}$ 且 $A_n \downarrow A \in \mathcal{F}$, 则 $P(A) = \lim_{n \rightarrow \infty} P(A_n)$ (从上连续).

如果概率空间 (Ω, \mathcal{F}, P) 的 P 零测集 (即零概率事件) 的每个子集仍为事件, 则称之为完备的概率空间. 为了避免 P 零测集的子集不是事件的情形出现, 我们把概率测度完备化. 令 \mathcal{N} 代表 Ω 的所有 P 零测集的子集的全体, 由 $\{\mathcal{F}, \mathcal{N}\}$ 生成的 σ 代数 (即包含 \mathcal{F} 和 \mathcal{N} 的最小 σ 代数) 称为 \mathcal{F} 的完备化, 记为 $\bar{\mathcal{F}}$. $\bar{\mathcal{F}}$ 中的每个集合 B 都可以表为 $B = A \cup N$, 其中 $A \in \mathcal{F}, N \in \mathcal{N}$, 且 $A \cap N = \emptyset$. 定义

$$\bar{P}(B) = \bar{P}(A \cup N) = P(A)$$

则 P 就被扩张到 $\bar{\mathcal{F}}$ 上.



容易验证, \bar{P} 是 $\bar{\mathcal{F}}$ 上的概率测度, 集函数 \bar{P} 称为 P 的完备化. 本书总假定 P 是完备的概率测度.

§1.2 随机变量和分布函数

定义 1.2.1 设 (Ω, \mathcal{F}, P) 是(完备的)概率空间, X 是定义在 Ω 上取值于实数集 \mathbb{R} 的函数, 如果对任意实数 $x \in \mathbb{R}$, $\{\omega : X(\omega) \leq x\} \in \mathcal{F}$, 则称 $X(\omega)$ 是 \mathcal{F} 上的随机变量, 简称为随机变量.

$$F(x) = P(\omega : X(\omega) \leq x), \quad -\infty < x < \infty$$

称为随机变量 X 的分布函数.



如果存在函数 $f(x)$, 满足

$$F(x) = \int_{-\infty}^x f(t) dt$$

则称 $f(x)$ 为随机变量 X 或其分布函数 $F(x)$ 的分布密度.

如果 X 具有分布密度, 则称 X 为连续型随机变量;

如果 X 最多以正概率取可数多个值, 则称 X 为离散型随机变量.

13/62

定义 1.2.2 两个随机变量 X 与 Y , 如果满足 $P(\omega \in \Omega : X(\omega) \neq Y(\omega)) = 0$, 则称它们是等价的.

注: 对于两个等价的随机变量, 我们视为同一.

定理 1.2.3 下列命题等价:

- (1) X 是随机变量;
- (2) $\{\omega : X(\omega) \geq a\} \in \mathcal{F}, \quad \forall a \in \mathbb{R};$



GoBack

FullScreen

Close

Quit



(3) $\{\omega : X(\omega) > a\} \in \mathcal{F}, \quad \forall a \in \mathbb{R};$

(4) $\{\omega : X(\omega) < a\} \in \mathcal{F}, \quad \forall a \in \mathbb{R}.$

注：为简单起见，习惯上将 $\{\omega : X(\omega) \geq a\}$ 记为 $\{X \geq a\}$,

其他类似记号自明.

定理 1.2.4 (1) 若 X, Y 是随机变量, 则 $\{X < Y\}, \{X \leq Y\}, \{X = Y\}$ 及 $\{X \neq Y\}$ 都属于 \mathcal{F} ;

(2) 若 X, Y 是随机变量, 则 $X \pm Y$ 与 XY 亦然;

(3) 若 $\{X_n\}$ 是随机变量序列, 则 $\sup_n X_n, \inf_n X_n, \limsup_{n \rightarrow \infty} X_n$ 和 $\liminf_{n \rightarrow \infty} X_n$ 都是随机变量.

映射 $\mathbf{X} : \Omega \rightarrow \mathbb{R}^d$, 表示为 $\mathbf{X} = (X_1, \dots, X_d)$, 若对所有的 $k, 1 \leq k \leq d, X_k$ 都是随机变量, 则称 \mathbf{X} 为随机向量.



复值随机变量 Z 定义为两个实值随机变量 X 和 Y 的线性组合 $X + iY$.

给定随机变量 X , 可以生成 Ω 上的 σ 代数, 即包含所有形如 $\{X \leq a\}, a \in \mathbb{R}$ 的最小 σ 代数, 记为 $\sigma(X)$. 类似可定义由随机变量 X_1, \dots, X_n 生成的 σ 代数 $\sigma(X_1, \dots, X_n)$.

常用的两种类型随机变量:

(1) 离散型随机变量 X 的概率分布用分布列描述:

$$p_k = P(X = x_k), \quad k = 1, 2, \dots$$

其分布函数 $F(x) = \sum_{x_k \leq x} p_k$.

(2) 连续型随机变量 X 的概率分布用概率密度 $f(x)$ 描述, 其分布函数

$$F(x) = \int_{-\infty}^x f(t) dt.$$



(3) 对于随机向量 $X = (X_1, \dots, X_d)$, 它的(d 维)分布函数(或联合分布函数) 定义为

$$F(x_1, \dots, x_d) = P(X_1 \leq x_1, \dots, X_d \leq x_d)$$

这里 d 为正整数, $x_k \in \mathbb{R}, k = 1, 2, \dots, d$.

定理 1.2.5 若 $F(x_1, \dots, x_d)$ 是联合分布函数, 则

- (1) $F(x_1, \dots, x_d)$ 对每个变量都是单调的;
- (2) $F(x_1, \dots, x_d)$ 对每个变量都是右连续的;
- (3) 对 $i = 1, 2, \dots, d$

$$\lim_{x_i \rightarrow -\infty} F(x_1, \dots, x_i, \dots, x_d) = 0,$$

$$\lim_{x_1, x_2, \dots, x_d \rightarrow \infty} F(x_1, x_2, \dots, x_d) = 1.$$

如果 $f(x_1, \dots, x_d) = \frac{\partial^d F}{\partial x_1 \dots \partial x_d}$ 对所有的 $(x_1, \dots, x_d) \in \mathbb{R}^d$ 存在, 则称函数 $f(x_1, \dots, x_d)$ 为 $F(x_1, \dots, x_d)$ 或



$X = (X_1, \dots, X_d)$ 的联合密度函数, 并且

$$F(x_1, \dots, x_d) = \int_{-\infty}^{x_1} \cdots \int_{-\infty}^{x_d} f(t_1, \dots, t_d) dt_d \cdots dt_1$$

设 $F(x_1, \dots, x_d)$ 为 X_1, \dots, X_d 的联合分布函数

$1 \leq k_1 < \dots < k_n \leq d$, 则 X_1, \dots, X_d 的边际分布 $F_{k_1, \dots, k_n}(x_{k_1}, \dots, x_{k_n})$

定义为

$$F_{k_1, \dots, k_n}(x_{k_1}, \dots, x_{k_n}) \\ = F(\infty, \dots, \infty, x_{k_1}, \infty, \dots, \infty, x_{k_2}, \infty, \dots, \infty, x_{k_n}, \infty, \dots, \infty)$$

一些常见分布:

1. 退化分布: 若随机变量 X 只取常数 c , 即

$$P\{X = c\} = 1$$

则 X 并不随机, 但我们把它看作随机变量的退化情况更为方便, 因此称之为退化分布, 又称单点分布.



2. Bernoulli分布:在一次试验中, 设事件 A 出现的概率为 $p, 0 < p < 1$, 不出现的概率为 $1 - p$, 若以 X 记事件 A 出现的次数, 则 X 的可能取值仅为 $0, 1$, 其对应的概率为

$$P\{X = k\} = p^k(1 - p)^{n-k}, \quad k = 0, 1$$

3. 二项分布:在 n 重Bernoulli试验中, 设事件 A 在每次试验中出现的概率均为 $p, 0 < p < 1$, 以 X 记事件 A 出现的次数, X 的可能取值为 $0, 1, 2, \dots, n$, 其对应的概率为

$$P\{X = k\} = \binom{n}{k} p^k(1 - p)^{n-k}, \quad k = 0, 1, \dots, n$$

则称之为以 n 和 p 为参数的二项分布, 简记为 $X \sim B(n, p)$.

4. Poisson 分布:若随机变量 X 可取一切非负整数



GoBack

FullScreen

Close

Quit

值, 且

$$P\{X = k\} = \frac{e^{-\lambda} \lambda^k}{k!}, \quad k = 0, 1, \dots$$

其中 $\lambda > 0$, 则称 X 服从Poisson分布, 记为 $X \sim P(\lambda)$.

5. 几何分布: 在Bernoulli试验中, 设事件 A 在每次试验中出现的概率均为 $p, 0 < p < 1$, 以 X 记事件 A 首次出现的试验次数, X 的可能取值为 $0, 1, 2, \dots$, 其对应的概率为

$$P\{X = k\} = p(1 - p)^{k-1}, \quad k \geq 1$$

则称之为几何分布.

6. Pascal分布: 在Bernoulli试验中, 设事件 A 在每次试验中出现的概率均为 $p, 0 < p < 1$, 以 X 记事件 A 第 r 次出现的试验次数, X 的可能取值为 $r, r + 1, \dots$, 其对应的概





率为

$$P\{X = k\} = \binom{k-1}{r-1} p^r (1-p)^{k-r}, \quad k = r, r+1, \dots$$

则称之为Pascal分布.

7. 负二项分布:对于任意实数 $r > 0$, 称

$$P\{X = k\} = \binom{k+r-1}{k} p^r (1-p)^k, \quad k = 0, 1, 2, \dots, \quad r > 0$$

为负二项分布.

负二项分布通常用于替换Poisson分布.同Poisson分布一样, 它也在非负整数上取值, 但因为它包含两个参数, 相比Poisson分布其变化更灵活. Poisson分布的方差和均值相等, 但负二项分布的方差大于均值, 这说明当某类数据集观测到的方差大于均值时, 负二项分布要比Poisson分



布更合适.

8. 离散均匀分布:如果分布列为

$$p_k = \frac{1}{n}, \quad k = 1, 2, \dots, n$$

则称之为离散均匀分布.

9. 连续均匀分布(简称均匀分布):如果密度函数为

$$f(x) = \begin{cases} [b-a]^{-1}, & \text{若 } a \leq x \leq b \\ 0, & \text{其他} \end{cases}$$

其中 $a < b$, 则称之为区间 $[a, b]$ 上的均匀分布.

10. 正态分布: 如果密度函数为

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \cdot \exp\{-(x-\mu)^2/2\sigma^2\}, x \in \mathbb{R}$$

则称之为参数为 μ 和 σ^2 的正态分布, 也称为 Gauss 分布, 记为 $X \sim N(\mu, \sigma^2)$.



11. d 维正态分布: 设 $\mu = (\mu_1, \dots, \mu_d)$, Σ 是 d 阶正定对称矩阵, 并且其行列式为 $|\Sigma|$. 如果其联合密度函数为

$$f(x_1, \dots, x_d) = (2\pi)^{-d/2} |\Sigma|^{-1/2} \exp\left\{-\frac{1}{2}(\mathbf{x}-\mu)' \Sigma^{-1}(\mathbf{x}-\mu)\right\}$$

则称之为 d 维正态分布, 记为 $X \sim N(\mu, \Sigma)$.

12. Γ 分布: 如果密度函数为

$$f(x) = \begin{cases} \frac{\lambda^s}{\Gamma(s)} x^{s-1} e^{-\lambda x}, & x \geq 0 \\ 0, & x < 0 \end{cases}$$

则称之为以 $s > 0$, $\lambda > 0$ 为参数的 Γ 分布, 其中 Γ 函数定义为

$$\Gamma(s) = \int_0^{\infty} e^{-x} x^{s-1} dx, \quad s > 0$$

13. 指数分布: 如果在 Γ 分布中令 $s = 1$, 即密度函数

为

$$f(x) = \begin{cases} \lambda e^{-\lambda x}, & x \geq 0 \\ 0, & x < 0 \end{cases}$$

则称之为指数分布.

14. χ^2 分布:如果在 Γ 分布中取 $s = \frac{n}{2}$, n 是正整数, $\lambda = \frac{1}{2}$, 即

$$f(x) = \frac{1}{2^{\frac{n}{2}} \Gamma(\frac{n}{2})} x^{\frac{n}{2}-1} e^{-\frac{x}{2}}, \quad x > 0$$

则称之为自由度是 n 的 χ^2 分布.



23/62



GoBack

FullScreen

Close

Quit



§1.3 数字特征、矩母函数与特征函数

§1.3.1 Riemann-Stieltjes积分

设 $g(x), F(x)$ 为有限区间 $(a, b]$ 上的实值函数, $a = x_0 < x_1 < \cdots < x_n = b$ 为 $(a, b]$ 的一个分割, 令

$$\Delta F(x_i) = F(x_i) - F(x_{i-1}), \xi_i \in [x_{i-1}, x_i], 1 \leq i \leq n,$$

$\lambda = \max_{1 \leq i \leq n} (x_i - x_{i-1})$, 如果当 $\lambda \rightarrow 0$ 时, 极限

$$\lim_{\lambda \rightarrow 0} \sum_{i=1}^n g(\xi_i) \Delta F(x_i)$$

存在, 且与分割的选择以及 $\xi_i \in [x_{i-1}, x_i]$ 的取法无关, 则称该极限值为函数 $g(x)$ 关于 $F(x)$ 在 $(a, b]$ 上的 Riemann-



Stieltjes积分, 记为

$$\int_a^b g(x) dF(x) = \lim_{\lambda \rightarrow 0} \sum_{i=1}^n g(\xi_i) \Delta F(x_i) \quad (1.3.1)$$

当 $F(x) = x$ 时, Riemann-Stieltjes积分即为Riemann积分. 关于Riemann-Stieltjes积分存在的条件, 这里不做进一步的讨论, 只给出一个简单的充分条件: 若函数 $g(x)$ 连续, $F(x)$ 单调, 则Riemann-Stieltjes积分存在. 本书中用到的 $g(x)$ 为连续函数, $F(x)$ 为分布函数, 因此积分的存在性不成问题. 为了后面的需要, 将积分推广到无限区间上:

$$\begin{aligned} \int_a^{+\infty} g(x) dF(x) &\doteq \lim_{b \rightarrow +\infty} \int_a^b g(x) dF(x) \\ \int_{-\infty}^b g(x) dF(x) &\doteq \lim_{a \rightarrow -\infty} \int_a^b g(x) dF(x) \end{aligned}$$



$$\int_{-\infty}^{+\infty} g(x) dF(x) \doteq \lim_{a \rightarrow -\infty, b \rightarrow +\infty} \int_a^b g(x) dF(x)$$

与Riemann积分不同的是

$$\int_{a-}^a dF(x) = \lim_{\delta \rightarrow 0+} \int_{a-\delta}^a dF(x) = F(a) - F(a-)$$

当 $F(x)$ 在 $x = a$ 处有跳跃时, 上式的值等于 $F(x)$ 在 a 点的跃度. 当 $F(x)$ 是一个阶梯函数时, Riemann-Stieltjes积分成为一个级数, 即设 $F(x)$ 在 $x = x_i$ 处有跃度 $p_i, i = 1, 2, \dots$, 则

$$\int_{-\infty}^{+\infty} g(x) dF(x) = \sum_{i=1}^{+\infty} g(x_i) p_i$$

Riemann-Stieltjes积分的一些基本性质:

(1) 线性性质:

$$\int_a^b [\alpha g_1(x) \pm \beta g_2(x)] dF(x) = \alpha \int_a^b g_1(x) dF(x) \pm \beta \int_a^b g_2(x) dF(x)$$



(2) 区间可加性:

$$\int_a^b g(x) dF(x) = \int_a^c g(x) dF(x) + \int_c^b g(x) dF(x)$$

(3) $\int_a^b dF(x) = F(b) - F(a)$, 其中 a, b 均可有限或无穷大.

$$(4) \int_a^b g(x) d[\alpha F_1(x) + \beta F_2(x)] = \alpha \int_a^b g(x) dF_1(x) + \beta \int_a^b g(x) dF_2(x)$$

(5) 若 $g(x) \geq 0$, $F(x)$ 单调不减, $b > a$, 则 $\int_a^b g(x) dF(x) \geq 0$.

27/62



GoBack

FullScreen

Close

Quit



§1.3.2 数字特征

定义 1.3.1 (1) 取值为 $\{s_k\}$ 的离散型随机变量 X 的数学期望 (简称为期望) $E[X]$ 定义为

$$E[X] = \sum_k s_k p_k = \sum_k s_k P(X = s_k)$$

如果 $\sum |s_k| p_k < \infty$.

(2) 连续型随机变量 X 的数学期望 $E[X]$ 定义为

$$E[X] = \int_{-\infty}^{\infty} x dF(x) = \int_{-\infty}^{\infty} x f(x) dx$$

如果 $\int_{-\infty}^{\infty} |x| dF(x) < \infty$, 这里 $F(x)$ 是 X 的分布函数, $f(x)$ 是其密度函数.

利用 Riemann-Stieltjes 积分, 我们可以对离散型随机



变量和连续型随机变量的期望给出一个统一的表达式:

$$E[X] = \int_{-\infty}^{+\infty} x dF(x)$$

(3) 设 X 为任一随机变量, 对正整数 k , 称 $m_k = E[X^k]$ 为 X 的 k 阶原点矩. 数学期望是一阶原点矩.

(4) 设 X 为任一随机变量, 对正整数 k , 称 $c_k = E[X - E[X]]^k$ 为 X 的 k 阶中心矩. 方差是二阶原点矩.

(5) 设 X, Y 为两个随机变量, 对正整数 k, l , 称 $E[X - E[X]]^k [Y - E[Y]]^l$ 为 X 的 $k + l$ 阶混合中心矩. 协方差是二阶混合中心矩.

§1.3.3 关于概率测度的积分

定义 1.3.2 设 (Ω, \mathcal{F}) 为一可测空间, \mathbb{R} 为实数域, $\bar{\mathbb{R}} =$



$\mathbb{R} \cup \{-\infty, \infty\}$, 分别用 $\mathcal{B}(\mathbb{R})$ 及 $\mathcal{B}(\bar{\mathbb{R}})$ 表示 \mathbb{R} 及 $\bar{\mathbb{R}}$ 上的 Borel σ 代数. 令 f 为 Ω 到 \mathbb{R} 中的一个映射, 如果 $f^{-1}(\mathcal{B}(\bar{\mathbb{R}})) \subset \mathcal{F}$, 则称 f 为 **Borel** 可测函数, 简称可测函数. 若进一步 f 只取实值, 则称 f 为实值可测函数.

如果存在实数 $a_k, 1 \leq k \leq n$ 和 Ω 的分割 $A_k \in \mathcal{F}, 1 \leq k \leq n$ (即 $\bigcup_{k=1}^n A_k = \Omega$, 且 $A_i \cap A_j = \emptyset, i \neq j, 1 \leq i, j \leq n$), 使得 $f(\omega) = \sum_{k=1}^n a_k I_{A_k}(\omega)$, 则称 f 为简单可测函数. 这里 $I_A(\cdot)$ 表示集合 A 的示性函数. 若 f 还可以表示为 $f = \sum_{j=1}^m b_j I_{B_j}$, 则当 $B_j \cap A_k \neq \emptyset$ 时, $b_j = a_k$. 于是, 通过将分割中的集合合并可以得到 f 的最简单表达式, 即表达式中的系数 a_k 互不相同.

以下给定一个完备的概率空间 (Ω, \mathcal{F}, P) . 用 \mathcal{S}^+ 表示 Ω 上非负简单可测函数全体, \mathcal{L}^+ 表示 Ω 上非负可测函



数全体, \mathcal{L} 表示 Ω 上可测函数全体.

首先我们定义非负简单可测函数关于概率测度的积分.

定义 1.3.3 令 S 表示所有非负简单可测函数 $h : \Omega \rightarrow R_+$. 如果 $h \in S$, 则定义其关于 P 的积分为

$$\int h dP = \sum_{k=1}^n a_k P(A_k) = E[h]$$

易知 $\int_{\Omega} f dP$ 不依赖于 f 的具体表达. 称 $\int_{\Omega} f dP$ 为 f 关于概率测度 P 的积分.

定理 1.3.4 (简单函数逼近定理) 设 (Ω, \mathcal{F}) 为一可测空间, $f \in \mathcal{L}$.

(1) 存在一简单可测函数序列 $(f_n, n \geq 1)$, 使得对一切 $n \geq 1$, 有 $|f_n| \leq |f|$, 且 $\lim_{n \rightarrow \infty} f_n = f$.

(2) 若 f 非负, 则存在非负简单可测函数的增序列 (f_n) ,



使得 $\lim_{n \rightarrow \infty} f_n = f$.

接下来定义非负可测函数的积分.

定义 1.3.5 设 $f \in \mathcal{L}^+$. 任取 $f_n \in \mathcal{S}^+$ 使得 $f_n \uparrow f$, 令

$$\int_{\Omega} f dP = \lim_{n \rightarrow \infty} \int_{\Omega} f_n dP$$

上述右端极限存在, 且不依赖于序列 (f_n) 的选取, 称 $\int_{\Omega} f dP$ 为 f 关于概率测度 P 的积分.

最后定义可测函数的积分.

定义 1.3.6 设 $f \in \mathcal{L}$. 令

$$f^+ = \max\{f, 0\} \quad \text{及} \quad f^- = -\min\{f, 0\}$$

注意到 $f^+ \geq 0, f^- \geq 0, f = f^+ - f^-, |f| = f^+ + f^-$. 如果 $\int_{\Omega} f^+ dP < \infty$ 或 $\int_{\Omega} f^- dP < \infty$, 则称 f 关于 P 的积分存



在.令

$$\int_{\Omega} f dP = \int_{\Omega} f^{+} dP - \int_{\Omega} f^{-} dP$$

如果 $\int_{\Omega} f^{+} dP < \infty$ 且 $\int_{\Omega} f^{-} dP < \infty$, 则称 f 关于概率测度 P 可积.

于是, 当随机变量 X 可积时, 它的期望就可以定义为

$$E[X] = \int_{\Omega} X dP$$

令 $\mathcal{L}^p(\Omega), p \geq 1$ 表示所有使得 $E[|X|^p] < \infty$ 的随机变量(等价类)全体, 简记为 \mathcal{L}^p .

关于 Ω 中样本点的某种性质 Π , 如果使得 Π 不成立的点的集合的概率是零, 则称 Π 几乎必然(almost surely) 或以概率1(with probability one)成立, 记为 $a.s.$ 或 $w.p.1$.

定理 1.3.7 设 f, g 积分存在.



(1) $\forall a \in \mathbb{R}$, af 的积分存在, 且 $\int_{\Omega} af dP = a \int_{\Omega} f dP$.

(2) 若 $f + g$ 处处有定义, 且 $\int_{\Omega} f dP + \int_{\Omega} g dP$ 处处有意义(即不出现 $\infty - \infty$), 则 $f + g$ 的积分存在, 且有 $\int_{\Omega} (f + g) dP = \int_{\Omega} f dP + \int_{\Omega} g dP$.

(3) 若取非负整数值随机变量 X 的期望存在, 则 $E[X] = \sum_{k=1}^{\infty} P\{X \geq k\}$.

(4) 若 N 为一零测集, 则 $\int_{\Omega} f I_N dP = 0$.

(5) 若 $f \leq g, a.s.$, 则 $\int_{\Omega} f dP \leq \int_{\Omega} g dP$.

(6) $|\int_{\Omega} f dP| \leq \int_{\Omega} |f| dP$.

(7) 设 $X \in \mathcal{L}^+$, 则 $E[X] = 0$ 当且仅当 $X = 0$ a.s.



GoBack

FullScreen

Close

Quit



§1.3.4 矩母函数

定义 1.3.8 若随机变量 X 的分布函数为 $F_X(x)$, 则称

$$\phi_X(t) = E[e^{tX}] = \int_{\Omega} e^{tX(\omega)} P(d\omega) = \int_{-\infty}^{\infty} e^{tx} dF_X(x) \quad (1.3.2)$$

为 X 的矩母函数.

注: X 的各阶矩与矩母函数的关系 (假设对 $\phi(t)$ 求导时, 求导运算与求期望运算可以交换次序)

$$\begin{aligned} \phi'(t) &= E(Xe^{tX}) \\ \phi''(t) &= E(X^2e^{tX}) \\ &\vdots \\ \phi^{(n)}(t) &= E(X^ne^{tX}) \end{aligned}$$



令 $t = 0$, 得到 $\phi^{(n)}(0) = E[X^n]$, $n \geq 1$. 当矩母函数存在时, 它唯一地决定分布, 因此我们能够用矩母函数刻画随机变量的概率分布. 但有时随机变量的矩母函数不一定存在, 在这种情况下, 更方便的是特征函数.

§1.3.5 特征函数

定义 1.3.9 若随机变量 X 的分布函数为 $F_X(x)$, 则称

$$\psi_X(t) = E[e^{itX}] = \int_{\Omega} e^{itX(\omega)} P(d\omega) = \int_{-\infty}^{\infty} e^{itx} dF_X(x)$$

为 X 的特征函数. 如果 F_X 有密度 $f(x)$, 则 $\psi_X(t)$ 就是 $f(x)$ 的 Fourier 变换

$$\psi_X(t) = \int_{-\infty}^{\infty} e^{itx} f(x) dx$$



特征函数是一个实变量的复值函数, 因为 $|e^{itx}| = 1$, 所以它对一切实数 t 都有定义. 特征函数有如下常用性质:

(1) 有界性: $|\psi(t)| \leq 1 = \psi(0)$;

(2) 共轭对称性: $\psi(-t) = \overline{\psi(t)}$;

(3) 一致连续性:

$$|\psi(t+h) - \psi(t)| \leq \int_{-\infty}^{\infty} |e^{ihx} - 1| dF(x);$$

(4) 线性变换的作用: 设 $Y = aX + b$, 则 Y 的特征函数是 $\psi_Y(t) = e^{ibt} \psi_X(at)$;

(5) 两个相互独立的随机变量之和的特征函数等于它们的特征函数之积.

(6) 非负定性: 对于任意的正整数 n , 任意实数 t_1, \dots, t_n 及复数 $\lambda_1, \dots, \lambda_n$, 有 $\sum_{k=1}^n \sum_{j=1}^n \psi(t_k - t_j) \lambda_k \overline{\lambda_j} \geq 0$.

(7) 设随机变量 X 有 n 阶矩存在, 则它的特征函数可微



分 n 次, 且当 $k \leq n$ 时, 有

$$\psi^{(k)}(0) = i^k E[X^k]$$

特别地, 特征函数可作如下带皮阿诺型余项的Taylor展开:

$$\psi(t) = 1 + itE[X] + \frac{(it)^2}{2!}E[X^2] + \cdots + \frac{(it)^n}{n!}E[X^n] + o(t)$$

例 1.3.10 求标准正态分布 $N(0, 1)$ 的特征函数.

解: 由定义 $\psi(t) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{itx} e^{-x^2/2} dx$

38/62



GoBack

FullScreen

Close

Quit



从而

$$\begin{aligned}\psi'(t) &= \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} ix e^{itx} e^{-x^2/2} dx \\ &= \frac{i}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{itx} d(-e^{-x^2/2}) \\ &= -\frac{i}{\sqrt{2\pi}} \left(e^{itx-x^2/2} \Big|_{-\infty}^{\infty} + t \int_{-\infty}^{\infty} e^{itx} e^{-x^2/2} dx \right) \\ &= -t\psi(t)\end{aligned}$$

解初值问题 $\psi'(t) + t\psi(t) = 0$, $\psi(0) = 1$ 得 $\psi(t) = e^{-\frac{1}{2}t^2}$.

例 1.3.11 求正态分布 $N(\mu, \sigma^2)$ 的特征函数.

解: 设 $Y \sim N(\mu, \sigma^2)$, $X \sim N(0, 1)$, 则有 $Y = \sigma X + \mu$.

利用性质(4)有 $\psi_Y(t) = e^{it\mu} \psi_X(\sigma t) = e^{i\mu t - \frac{1}{2}\sigma^2 t^2}$.

由于特征函数只与分布函数有关, 所以称为分布的特征函数. 另一方面, 有下述定理.



GoBack

FullScreen

Close

Quit



定理 1.3.12 (唯一性定理) 分布函数由其特征函数唯一决定.

从而说明特征函数与分布函数是相互唯一确定的.

若随机向量 (X_1, \dots, X_n) 的分布函数为 $F(x_1, \dots, x_n)$, 与随机变量相仿, 类似地定义它的特征函数

$$\psi(t_1, \dots, t_n) = \int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} e^{i(t_1 x_1 + \dots + t_n x_n)} dF(x_1, \dots, x_n)$$

可以类似于一元的情况, 建立起 n 元特征函数的理论.

例如, 我们考虑在上1.2节中定义的 d 维正态分布, 简称为多元正态分布, 这个定义在推导很多性质时并不方便, 同时还不能考虑 Σ 不是正定的情形, 为此, 我们采用下面的定义. 如果随机变量 X 的特征函数为

$$\psi_X(t) = \exp\{it'\mu - \frac{1}{2}t'\Sigma t\}$$



则称 \mathbf{X} 服从多元正态分布 $N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$. 其中 $\mathbf{X} = (X_1, \dots, X_c)'$, $(\cdot)'$ 表示 (\cdot) 的转置, $\mathbf{t} = (t_1, \dots, t_d)'$, $\boldsymbol{\mu} = (\mu_1, \dots, \mu_d)'$, $\boldsymbol{\Sigma}$ 是非负定 $d \times d$ 矩阵. 当 $\boldsymbol{\mu} = \mathbf{0}$, $\boldsymbol{\Sigma} = \mathbf{I}_d$ 时, 称为标准多元正态分布, 记为 $\mathbf{X} \sim N(\mathbf{0}, \mathbf{I}_d)$.

利用特征函数方法不难证明下面几个命题:

命题 1.3.13 若 $\mathbf{X} \sim N(\mathbf{0}, \mathbf{I}_d)$, 则 \mathbf{X} 的任一线性函数 $\mathbf{Y} = \mathbf{A}_{n \times d} \mathbf{X} + \boldsymbol{\mu}$ 服从 n 维正态分布 $N(\boldsymbol{\mu}, \mathbf{A} \mathbf{A}')$.

命题 1.3.14 若 $\mathbf{Y} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, 则 $\mathbf{A} \mathbf{Y} + \mathbf{b} \sim N(\mathbf{A} \boldsymbol{\mu} + \mathbf{b}, \mathbf{A} \boldsymbol{\Sigma} \mathbf{A}')$.



§1.4 收敛性

定义 1.4.1 (1) 设 $\{X_n, n \geq 1\}$ 是随机变量序列, 若存在随机变量 X 使得

$$P\{\omega \in \Omega : X(\omega) = \lim_{n \rightarrow \infty} X_n(\omega)\} = 1$$

则称随机变量序列 $\{X_n, n \geq 1\}$ 几乎必然收敛(或以概率1收敛)于 X , 记为 $X_n \rightarrow X, a.s.$ 或 $X_n \xrightarrow{a.s.} X$.

(2) 设 $\{X_n, n \geq 1\}$ 是随机变量序列, 若存在随机变量 X 使得 $\forall \varepsilon > 0$, 有

$$\lim_{n \rightarrow \infty} P\{|X_n - X| \geq \varepsilon\} = 0$$

则称随机变量序列 $\{X_n, n \geq 1\}$ 依概率收敛于 X , 记为 $X_n \xrightarrow{P} X$.



(3) 设随机变量序列 $\{X_n\} \subset \mathcal{L}^p, p \geq 1, X \in \mathcal{L}^p$, 若有

$$\lim_{n \rightarrow \infty} E[|X_n - X|^p] = 0$$

则称随机变量序列 $\{X_n, n \geq 1\}$ p 次平均收敛于 X , 或称 $\{X_n\}$ 在 \mathcal{L}^p 中强收敛于 X . 当 $p = 2$ 时, 称为均方收敛.

(4) 设 $\{F_n(x)\}$ 是分布函数列, 如果存在一个单调不减函数 $F(x)$, 使得在 $F(x)$ 的所有连续点 x 上均有

$$\lim_{n \rightarrow \infty} F_n(x) = F(x)$$

则称 $\{F_n(x)\}$ 弱收敛于 $F(x)$, 记为 $F_n(x) \xrightarrow{W} F(x)$.

设随机变量 X_n, X 的分布函数分别为 $F_n(x)$ 及 $F(x)$, 若 $F_n(x) \xrightarrow{W} F(x)$, 则称 $\{X_n\}$ 依分布收敛于 X , 记为 $X_n \xrightarrow{L} X$.

定理 1.4.2 (1) 随机变量序列 $X_n \xrightarrow{a.s.} X$ 的充分必要

条件是 $\forall \varepsilon > 0$,

$$\lim_{n \rightarrow \infty} P\left\{\sup_{m \geq n} |X_m - X| \geq \varepsilon\right\} = 0$$

(2) 随机变量序列 $X_n \xrightarrow{P} X$ 的充分必要条件是 $\{X_n\}$ 的任意子序列都包含几乎必然收敛于 X 的子序列.

随机变量序列的这4种收敛性之间的关系可以总结为下面的关系图:

几乎必然收敛 \implies 依概率收敛 \implies 依分布收敛;

p 次平均收敛 \implies 依概率收敛 \implies 依分布收敛.

注: 几乎必然收敛与 p 阶矩收敛之间没有蕴含关系.

例 1.4.3 取 $\Omega = (0, 1]$, \mathcal{F} 为 $(0, 1]$ 中全体Borel子集所构成的 σ -代数, P 为Lebesgue测度, 我们可以构造出2个随机





变量序列,其中之一是 r 阶矩收敛的,但是不几乎必然收敛;
另外一个则几乎必然收敛,但不是 r 阶矩收敛的.

令

$$Y_{11} = 1; \quad Y_{21} = \begin{cases} 1, & \omega \in (0, \frac{1}{2}] \\ 0, & \omega \in (\frac{1}{2}, 1] \end{cases}$$

$$Y_{22} = \begin{cases} 0, & \omega \in (0, \frac{1}{2}] \\ 1, & \omega \in (\frac{1}{2}, 1] \end{cases}$$

一般地, 将 $(0, 1]$ 分成 k 个等长区间, 并且令

$$Y_{ki} = \begin{cases} 1, & \omega \in (\frac{i-1}{k}, \frac{i}{k}] \\ 0, & \omega \notin (\frac{i-1}{k}, \frac{i}{k}] \end{cases} \quad i = 1, \dots, k, \quad k = 1, 2, \dots$$

定义随机变量序列

$$X_1 = Y_{11}, \quad X_2 = Y_{21}, \quad X_3 = Y_{22}, \quad X_4 = Y_{31}, \quad X_5 = Y_{32}, \dots$$



对任意 $\varepsilon > 0$, 由于

$$E|Y_{ki} - 0|^r = \frac{1}{k} \rightarrow 0, (k \rightarrow \infty)$$

可见 $\{X_n\}$ 为 r 阶矩收敛, 但是对任意固定的 $\omega \in \Omega$, 任一自然数 k , 恰有一个 i , 使得 $Y_{ki}(\omega) = 1$, 而对其余的 j 有 $Y_{kj}(\omega) = 0$. 由此知 $\{X_n(\omega)\}$ 中有无穷多个 1 及无穷多个 0, 于是 $\{X_n(\omega)\}$ 对每个 $\omega \in \Omega$ 都不收敛.

如果取

$$Z_n = \begin{cases} n^{\frac{1}{r}}, & \text{若 } \omega \in (0, \frac{1}{n}] \\ 0, & \text{若 } \omega \notin (0, \frac{1}{n}] \end{cases}$$
$$Z = 0, \quad \forall \omega \in \Omega$$

易见, $Z_n(\omega) \rightarrow Z(\omega) \quad \forall \omega \in \Omega$, 所以

$$Z_n \rightarrow Z, \quad a.s.$$



但是 $E(|Z_n - Z|^r) = n \cdot \frac{1}{n} = 1 \not\rightarrow 0$.

下面我们给出积分号下取极限的三大基本定理.

定理 1.4.4 (单调收敛定理) 设 $f_n \in \mathcal{L}$ 的积分存在, $n \geq 1$, 则:

(1) 设 $f_n \uparrow f, a.s.$, 若 $\int_{\Omega} f_1 dP > -\infty$, 则 f 的积分存在, 且 $\int_{\Omega} f_n dP \uparrow \int_{\Omega} f dP$;

(2) 设 $f_n \downarrow f, a.s.$, 若 $\int_{\Omega} f_1 dP < \infty$, 则 f 的积分存在, 且 $\int_{\Omega} f_n dP \downarrow \int_{\Omega} f dP$.

定理 1.4.5 (Fatou引理) 设随机变量序列 $\{X_n\}$ 的期望存在, $n \geq 1$, 则

$$E[\liminf_{n \rightarrow \infty} X_n] \leq \liminf_{n \rightarrow \infty} E[X_n] \leq \limsup_{n \rightarrow \infty} E[X_n] \leq E[\limsup_{n \rightarrow \infty} X_n]$$

定理 1.4.6 (Lebesgue控制收敛定理) 设 $f_n, f \in$



\mathcal{L} , $f_n \xrightarrow{a.s.} f$ 或 $f_n \xrightarrow{P} f$. 若存在一非负可积函数 g , 使得 $\forall n \geq 1$ 有 $|f_n| \leq g, a.s.$, 则 f 可积, 且有 $\lim_{n \rightarrow \infty} \int_{\Omega} f_n dP = \int_{\Omega} f dP$.

§1.5 独立性与条件期望

§1.5.1 独立性

定义 1.5.1 (1) 设 A, B 为两个事件, 若 $P(A \cap B) = P(A)P(B)$, 则称 A 与 B 独立. 更一般地, 设 A_1, A_2, \dots, A_n 为 n 个事件, 如果对任何 $m \leq n$ 及 $1 \leq k_1 < k_2 < \dots < k_m \leq n$, 有

$$P\left(\bigcap_{j=1}^m A_{k_j}\right) = \prod_{j=1}^m P(A_{k_j})$$



则称 A_1, A_2, \dots, A_n 相互独立. A_1, A_2, \dots, A_n 两两独立不一定相互独立.

(2) 设 $\{A_i, i \in I\}$ 是一族事件, 若 对 I 的任意有限子集 $\{i_1, \dots, i_k\} \neq \emptyset$ 有

$$P\left(\bigcap_{j=1}^k A_{i_j}\right) = \prod_{j=1}^k P(A_{i_j}) \quad (1.5.1)$$

则称 $\{A_i, i \in I\}$ 是相互独立的.

(3) 设 $\{\mathcal{A}_i, i \in I\}$ 是一族事件类, 如果对 I 的任意有限子集 $\{i_1, \dots, i_k\} \neq \emptyset$, 任意 $A_{i_j} \in \mathcal{A}_{i_j}$ 有(1.5.1)式成立, 则称 $\{\mathcal{A}_i, i \in I\}$ 是独立事件类.

(4) 设 $\{X_i, i \in I\}$ 是 Ω 上一族随机变量, 如果 σ 代数族 $\{\sigma(X_i), i \in I\}$ 是独立事件类, 则称 $\{X_i, i \in I\}$ 相互独立.



容易证明随机变量 X_1, \dots, X_n 独立的充分必要条件是它们的联合分布函数可以分解为

$$F(x_1, \dots, x_n) = F_{X_1}(x_1) \cdots F_{X_n}(x_n)$$

定理 1.5.2 (1) 设随机变量 $X_1, \dots, X_n \in \mathcal{L}^1$ 是独立的, 则 $E[\prod_{k=1}^n X_k] = \prod_{k=1}^n E[X_k]$.

(2) 设随机变量 $X_1, \dots, X_n \in \mathcal{L}^2$ 是独立的, 则 $Var[\sum_{k=1}^n X_k] = \sum_{k=1}^n Var[X_k]$. 50/62

定理 1.5.3 (Borel-Cantelli 第一引理)

设 $\{A_n, n \geq 1\}$ 是一列事件, 若 $\sum_{n=1}^{\infty} P(A_n) < \infty$, 则 $P(A_n, i.o.) = 0$.

定理 1.5.4 (Borel-Cantelli 第二引理)

设 $\{A_n, n \geq 1\}$ 是一独立的事件列, 若 $\sum_{n=1}^{\infty} P(A_n) =$



GoBack

FullScreen

Close

Quit



∞ , 则 $P(A_n, i.o.) = 1$.

定义 1.5.5 设 $\{X_n, n \geq 1\}$ 是随机变量序列, $\mathcal{D}_k = \sigma(X_k, X_{k+1}, \dots)$ 是由 X_k, X_{k+1}, \dots 生成的 σ 代数, 则 $\{\mathcal{D}_k\}$ 是非增的列, 它们的交 $\mathcal{D} = \bigcap_{n \geq 1} \mathcal{D}_n$ 称为序列 $\{X_n, n \geq 1\}$ 的尾 σ 代数, \mathcal{D} 中的元素称为 $\{X_n, n \geq 1\}$ 的尾事件.

定理 1.5.6 (Kolmogorov 0-1律)

独立随机变量序列的尾事件的概率或为0或为1.

§1.5.2 独立随机变量和的分布

设随机变量 X_1, X_2 相互独立, F_1, F_2 分别为它们的分布函数. 令 $X = X_1 + X_2$, 其分布函数记为 $F_X(x)$. 则由独立



GoBack

FullScreen

Close

Quit

性,有

$$\begin{aligned} F_X(x) &= P\{X_1 + X_2 \leq x\} \\ &= \int_{-\infty}^{\infty} P\{X_1 + X_2 \leq x | X_1 = t\} dF_1(t) \\ &= \int_{-\infty}^{\infty} F_2(x - t) dF_1(t) \end{aligned} \quad (1.5.2)$$

上述第三个等号右端称作分布函数 F_1, F_2 的卷积, 记为 $F_1 * F_2(x)$. 一般地对有界函数 $g(x)$ 和一个单调函数 $F(x)$, 都可以定义 F 与 g 的卷积:

$$F * g(x) \triangleq \int_{-\infty}^{\infty} g(x - t) dF(t)$$

这里需要注意的是 $F * g$ 的顺序, $g * F$ 可能没有意义. 但是当 F 和 g 都是分布函数时, 卷积可以交换顺序. 只需注意到





卷积中的随机变量 X_1 和 X_2 的地位是对等的即可得到

$$F_1 * F_2(x) = F_2 * F_1(x)$$

不但如此, 容易看出, 对于分布函数, 卷积还满足结合律和分配律. 即设 F, G, H 为分布函数, 则有

$$(F * G) * H(x) = F * (G * H)(x)$$

$$F * (G + H)(x) = F * G(x) + F * H(x)$$

于是, 更进一步还有, 设 $X_k, k = 1, 2, \dots, n$ 是独立同分布 F 的随机变量, 令 $S_0 = 0, S_n = \sum_{k=1}^n X_k, n = 1, 2, \dots$, S_n 的分布记作 F_n , 则有

$$F_0(x) = \begin{cases} 0, & x < 0 \\ 1, & x \geq 0 \end{cases}$$

$$F_n(x) = F * F_{n-1}(x), n = 1, 2, \dots$$



称 F_n 为 F 的 n 重卷积.

§1.5.3 条件期望

设 B 是一个事件, 且 $P(B) > 0$. 则事件 B 发生的条件下事件 A 发生的条件概率为

$$P(A|B) = P(A \cap B) / P(B)$$

定理 1.5.7 (全概率公式) 设 $\{B_n\}$ 是 Ω 的一个分割, 且使得 $P(B_n) > 0, \forall n$. 如果 $A \in \mathcal{F}$, 则

$$P(A) = \sum_n P(B_n)P(A|B_n)$$

定理 1.5.8 (Bayes公式) 设 $\{B_n\}$ 是 Ω 的一个分割, 且使得 $P(B_n) > 0, \forall n$, 如果 $P(A) > 0$, 则

$$P(B_k|A) = \frac{P(B_k)P(A|B_k)}{\sum_n P(B_n)P(A|B_n)}, \quad n \geq 1$$



如果 X 与 Y 是离散型随机变量, 对一切使得 $P\{Y = y\} > 0$ 的 y , 给定 $Y = y$ 时, X 的条件概率定义为:

$$P\{X = x|Y = y\} = \frac{P\{X = x, Y = y\}}{P\{Y = y\}}$$

X 的条件分布定义为:

$$F(x|y) = P\{X \leq x|Y = y\}$$

X 的条件期望定义为:

$$E[X|Y = y] = \int x dF(x|y) = \sum_x x P\{X = x|Y = y\}$$

如果 X 与 Y 有联合概率密度函数 $f(x, y)$, 则对一切使得

$f_Y(y) \geq 0$ 的 y , 给定 $Y = y$ 时, X 的条件概率密度函数定义为:

$$f(x|y) = \frac{f(x, y)}{f_Y(y)}$$



X 的条件分布定义为:

$$F(x|y) = P\{X \leq x|Y = y\} = \int_{-\infty}^x f(x|y)dx$$

X 的条件期望定义为:

$$E[X|Y = y] = \int x dF(x|y) = \int x f(x|y)dx$$

我们以 $E[X|Y]$ 表示随机变量 Y 的函数,它在 $Y = y$ 时,取值为 $E[X|Y = y]$.条件期望的一个重要性质是对一切随机变量 X 和 Y ,当期望存在时,有

$$E[X] = E[E[X|Y]] = \int E[X|Y = y]dF_Y(y) \quad (1.5.3)$$

当 Y 为一个离散随机变量时,(1.5.3)式为

$$E[X] = \sum_y E[X|Y = y]P\{Y = y\}$$



当 Y 为一个连续随机变量时, (1.5.3)式为

$$E[X] = \int_{-\infty}^{+\infty} E[X|Y=y]f(y)dy$$

例 1.5.9 (随机个随机变量之和) 设 X_1, X_2, \dots 是一列与 X 独立同分布的随机变量; 设 N 为一非负整值随机变量, 且与序列 X_1, X_2, \dots 独立. 求 $Y = \sum_{i=1}^N X_i$ 的均值和方差.

解 首先在对 N 取条件的情况下来计算 $Y = \sum_{i=1}^N X_i$ 的矩母函数, 即

$$E[\exp\{t \sum_{i=1}^N X_i\} | N=n] = E[\exp\{t \sum_{i=1}^N X_i\}] = (\phi_X(t))^n$$

其中 $\phi_X(t)$ 是随机变量 X 的矩母函数, 因此

$$E[\exp\{t \sum_{i=1}^N X_i\} | N] = (\phi_X(t))^N$$



从而

$$\phi_Y(t) = E[\exp\{t \sum_{i=1}^N X_i\}] = E[(\phi_X(t))^N]$$

现在对 $\phi_Y(t)$ 求导得

$$\phi_Y'(t) = E[N(\phi_X(t))^{N-1} \phi_X'(t)]$$

再求一次导数得

$$\phi_Y''(t) = E[N(N-1)(\phi_X(t))^{N-2} (\phi_X'(t))^2 + N(\phi_X(t))^{N-1} \phi_X''(t)]$$

计算在 $t = 0$ 点的值, 得

$$E[Y] = E[NE[X]] = E[N]E[X] \quad (1.5.4)$$

及

$$E[Y^2] = E[N(N-1)(E[X])^2 + NE[X^2]] = E[N]Var[X] + E[N^2](E[X])^2$$



因此有

$$\text{Var}[Y] = E[Y^2] - (E[Y])^2 = E[N]\text{Var}[X] + (E[x])^2\text{Var}[N] \quad (1.5.5)$$

最后我们将条件期望推广到一般随机变量及 σ 代数情形.

设 X 是随机变量, B 是事件且 $P(B) > 0$, 则给定事件 B , 随机变量 X 的条件期望 定义为

$$E[X|B] = \int X dP_B = [P(B)]^{-1} \int_B X dP = [P(B)]^{-1} E[XI_B]$$

定义 1.5.10 设 X 是随机变量且 $E[|X|] < \infty$. 若对每个子 σ 代数 $\mathcal{G} \subset \mathcal{F}$, 存在唯一的(几乎必然相等的意义下)随机变量 X^* , 有 $E[|X^*|] < \infty$, 使得 X^* 是 \mathcal{G} 可测随机变量(即



对任何的 $a \in \mathbb{R}$, 有 $\{X^* \leq a\} \in \mathcal{G}$), 且

$$E[X^* I_B] = E[X I_B], \quad \forall B \in \mathcal{G}$$

则称随机变量 X^* 为 X 在给定 \mathcal{G} 下的条件期望, 记为 $X^* = E[X|\mathcal{G}]$. 即

$$\int_B E[X|\mathcal{G}] dP = \int_B X dP, \quad \forall B \in \mathcal{G}$$

定理 1.5.11 条件期望有如下基本性质:

- (1) $E[E[X|\mathcal{G}]] = E[X]$.
- (2) 若 X 是 \mathcal{G} 可测, 则 $E[X|\mathcal{G}] = X, a.s..$
- (3) 设 $\mathcal{G} = \{\emptyset, \Omega\}$, 则 $E[X|\mathcal{G}] = E[X], a.s..$
- (4) $E[X|\mathcal{G}] = E[X^+|\mathcal{G}] - E[X^-|\mathcal{G}], a.s..$
- (5) 若 $X \leq Y, a.s..$, 则 $E[X|\mathcal{G}] \leq E[Y|\mathcal{G}], a.s..$



(6) 若 a, b 为实数, $X, Y, aX + bY$ 的期望存在, 则

$$E[aX + bY|\mathcal{G}] = aE[X|\mathcal{G}] + bE[Y|\mathcal{G}], a.s.$$

如果右边和式有意义.

(7) $|E[X|\mathcal{G}]| \leq E[|X||\mathcal{G}], a.s..$

(8) 设 $0 \leq X_n \uparrow X, a.s.$, 则 $E[X_n|\mathcal{G}] \uparrow E[X|\mathcal{G}], a.s..$

(9) 设 X 及 XY 的期望存在, 且 Y 为 \mathcal{G} 可测, 则

$$E[XY|\mathcal{G}] = YE[X|\mathcal{G}], a.s.$$

(10) 若 X 与 \mathcal{G} 相互独立(即 $\sigma(X)$ 与 \mathcal{G} 相互独立), 则有

$$E[X|\mathcal{G}] = E[X], a.s.$$

(11) 若 $\mathcal{G}_1, \mathcal{G}_2$ 是两个子 σ 代数, 使得 $\mathcal{G}_1 \subset \mathcal{G}_2 \subset \mathcal{F}$, 则

$$E[E[X|\mathcal{G}_2]|\mathcal{G}_1] = E[X|\mathcal{G}_1], a.s.$$



(12) 若 X, Y 是两个独立的随机变量, 函数 $g(x, y)$ 使得 $E[|g(X, Y)|] < +\infty$, 则有

$$E[g(X, Y)|Y] = E[g(X, y)]|_{y=Y}, \quad a.s.$$

这里 $E[g(X, y)]|_{y=Y}$ 的意义是, 先将 y 视为常数, 求得数学期望 $E[g(X, y)]$ 后再将随机变量 Y 代入到 y 的位置.

定义 1.5.12 设 $f(x_1, \dots, x_d)$ 是随机变量 X_1, \dots, X_d 的联合密度函数, 则 X_1, \dots, X_k 在给定 X_{k+1}, \dots, X_d 时的条件密度 $f_{1, \dots, k}(u_1, \dots, u_k | x_{k+1}, \dots, x_d)$ 定义为

$$\begin{aligned} & f_{1, \dots, k}(u_1, \dots, u_k | x_{k+1}, \dots, x_d) \\ &= \frac{f(u_1, \dots, u_k, x_{k+1}, \dots, x_d)}{\int_{\mathbb{R}} \cdots \int_{\mathbb{R}} f(y_1, \dots, y_k, x_{k+1}, \dots, x_d) dy_1 \cdots dy_k} \end{aligned}$$